CLASIFICACIÓN AUTOMATICA DE TUMORES CEREBRALES

CNN

Carrascosa Justina
Della Rosa Ana Laura

24 de julio 2025

ÍNDICE

1. Introducción
2. Objetivos
3. Intento Inicial
4. Plan de Acción
5. Base de Datos
6. Preprocesamiento
7. Entrenamiento
8. Resultados
9. Conclusiones

OBJETIVOS

General

Desarrollar un modelo de aprendizaje profundo basado en redes neuronales convolucionales (CNN) que permita clasificar imágenes de resonancia magnética cerebral en diferentes tipos de tumores cerebrales o ausencia de ellos, de forma automática y precisa.

Específicos

- Recolectar y organizar una base de datos de imágenes de resonancia magnética cerebral, clasificadas según el tipo de tumor.
- Definir y entrenar una red neuronal convolucional (CNN) propia para realizar la tarea de clasificación.
- Analizar visualmente el proceso de entrenamiento y validación a través de gráficos de evolución de métricas.
- Evaluar y comparar el rendimiento de los modelos desarrollados mediante métricas como precisión, pérdida y matriz de confusión.

INTENTO INICIAL

Primer enfoque

Primero implementamos una red neuronal convolucional (CNN) propia desde cero con varias capas de convolución, normalización, activaciones ReLU, pooling, y capas densas.

Problema detectado

Debido a la cantidad limitada de imágenes, el modelo no logró generalizar correctamente:

- Overfitting evidente
- Baja precisión en validación
- Resultados inestables

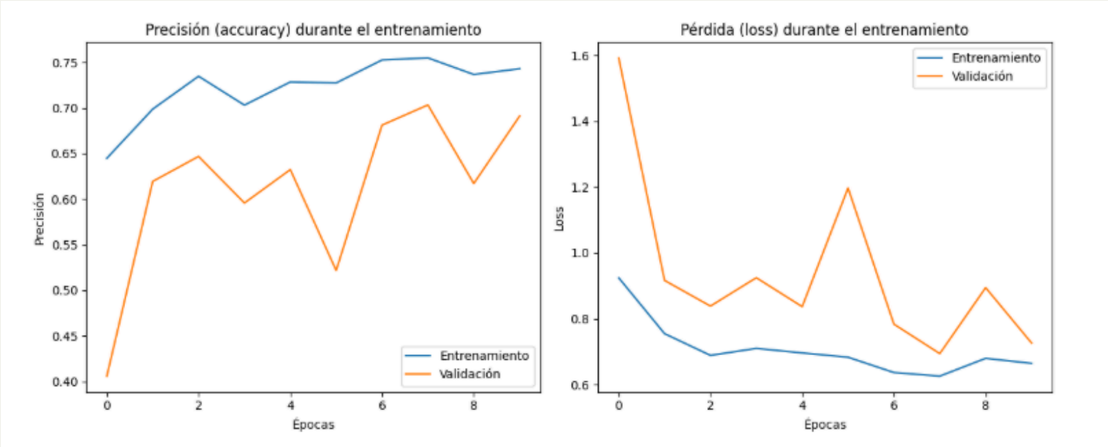

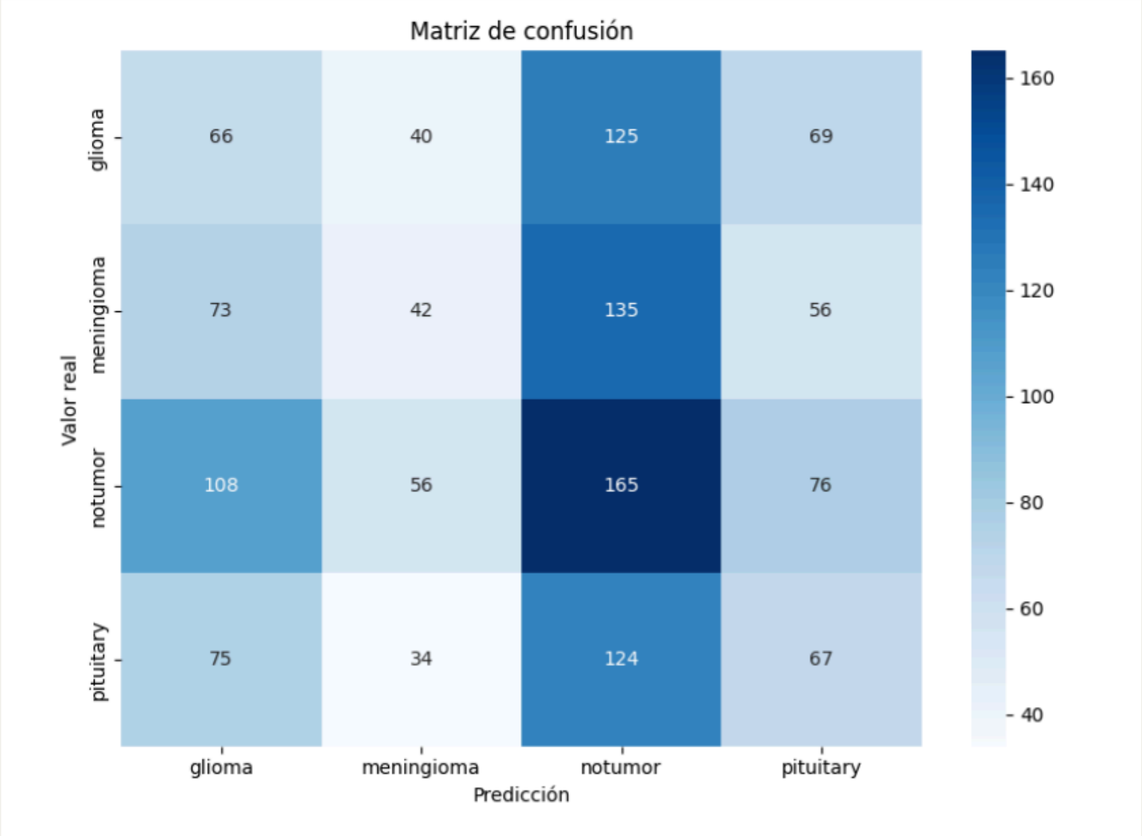

Solución adoptada

Optamos por Transfer Learning con VGG16, una arquitectura preentrenada en ImageNet, que permite aprovechar características previamente aprendidas y mejorar el rendimiento con pocos datos.

PLAN DE ACCIÓN

Base de Datos

Se utilizó un conjunto de datos de Kaggle con imágenes de resonancia magnética cerebral (MRI)

Preprocesamiento

Se aplicaron técnicas de aumento de datos (data augmentation) Además, se utilizaron tecnicas normalizar y redimencionar las imágenes.

VGG16

Se empleó la arquitectura VGG16 y se realizaron modificaciones pertinenetes para adaptarlo al problema

Entrenamiento

Para el entrenamiento del modelo se utilizó un optimizador eficiente y una función de pérdida adecuada para clasificación múltiple. Además, se implementaron mecanismos para controlar el entrenamiento y mejorar la generalización, evitando que el modelo se sobreajuste a los datos.

Prueba

El modelo fue evaluado sobre el conjunto de test separado. Se analizaron métricas como accuracy, precision, recall, f1-score y matriz de confusión, mostrando una buena capacidad de generalización en la detección de tumores.

BASE DE DATOS

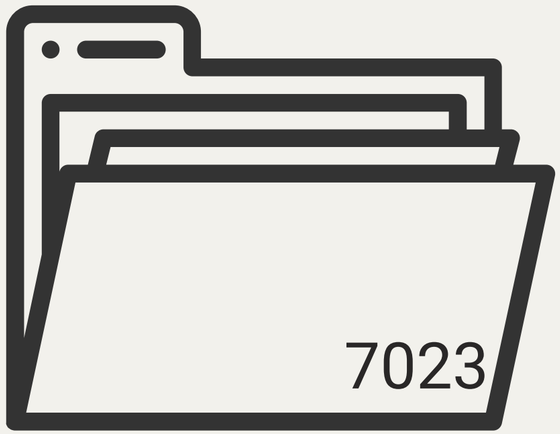

Training

	Cantidad de imagenes
Glioma	1321
Meningioma	1339
No tumor	1595
Pituitario	1457

Testing

Glioma	300
Meningioma	306
No tumor	405
Pituitario	300

Ejemplos de imagenes por clase

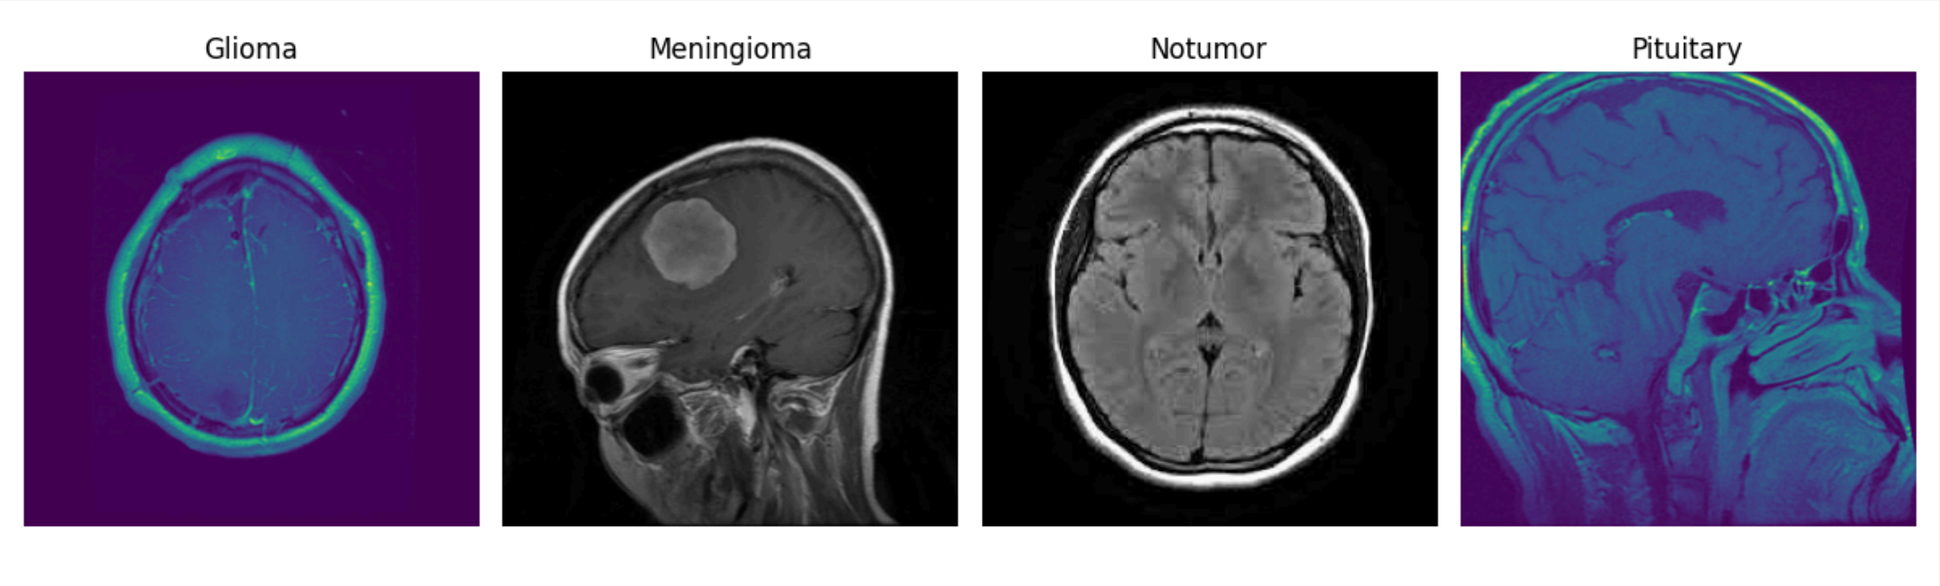

Chequeo de balance de clases en el dataset

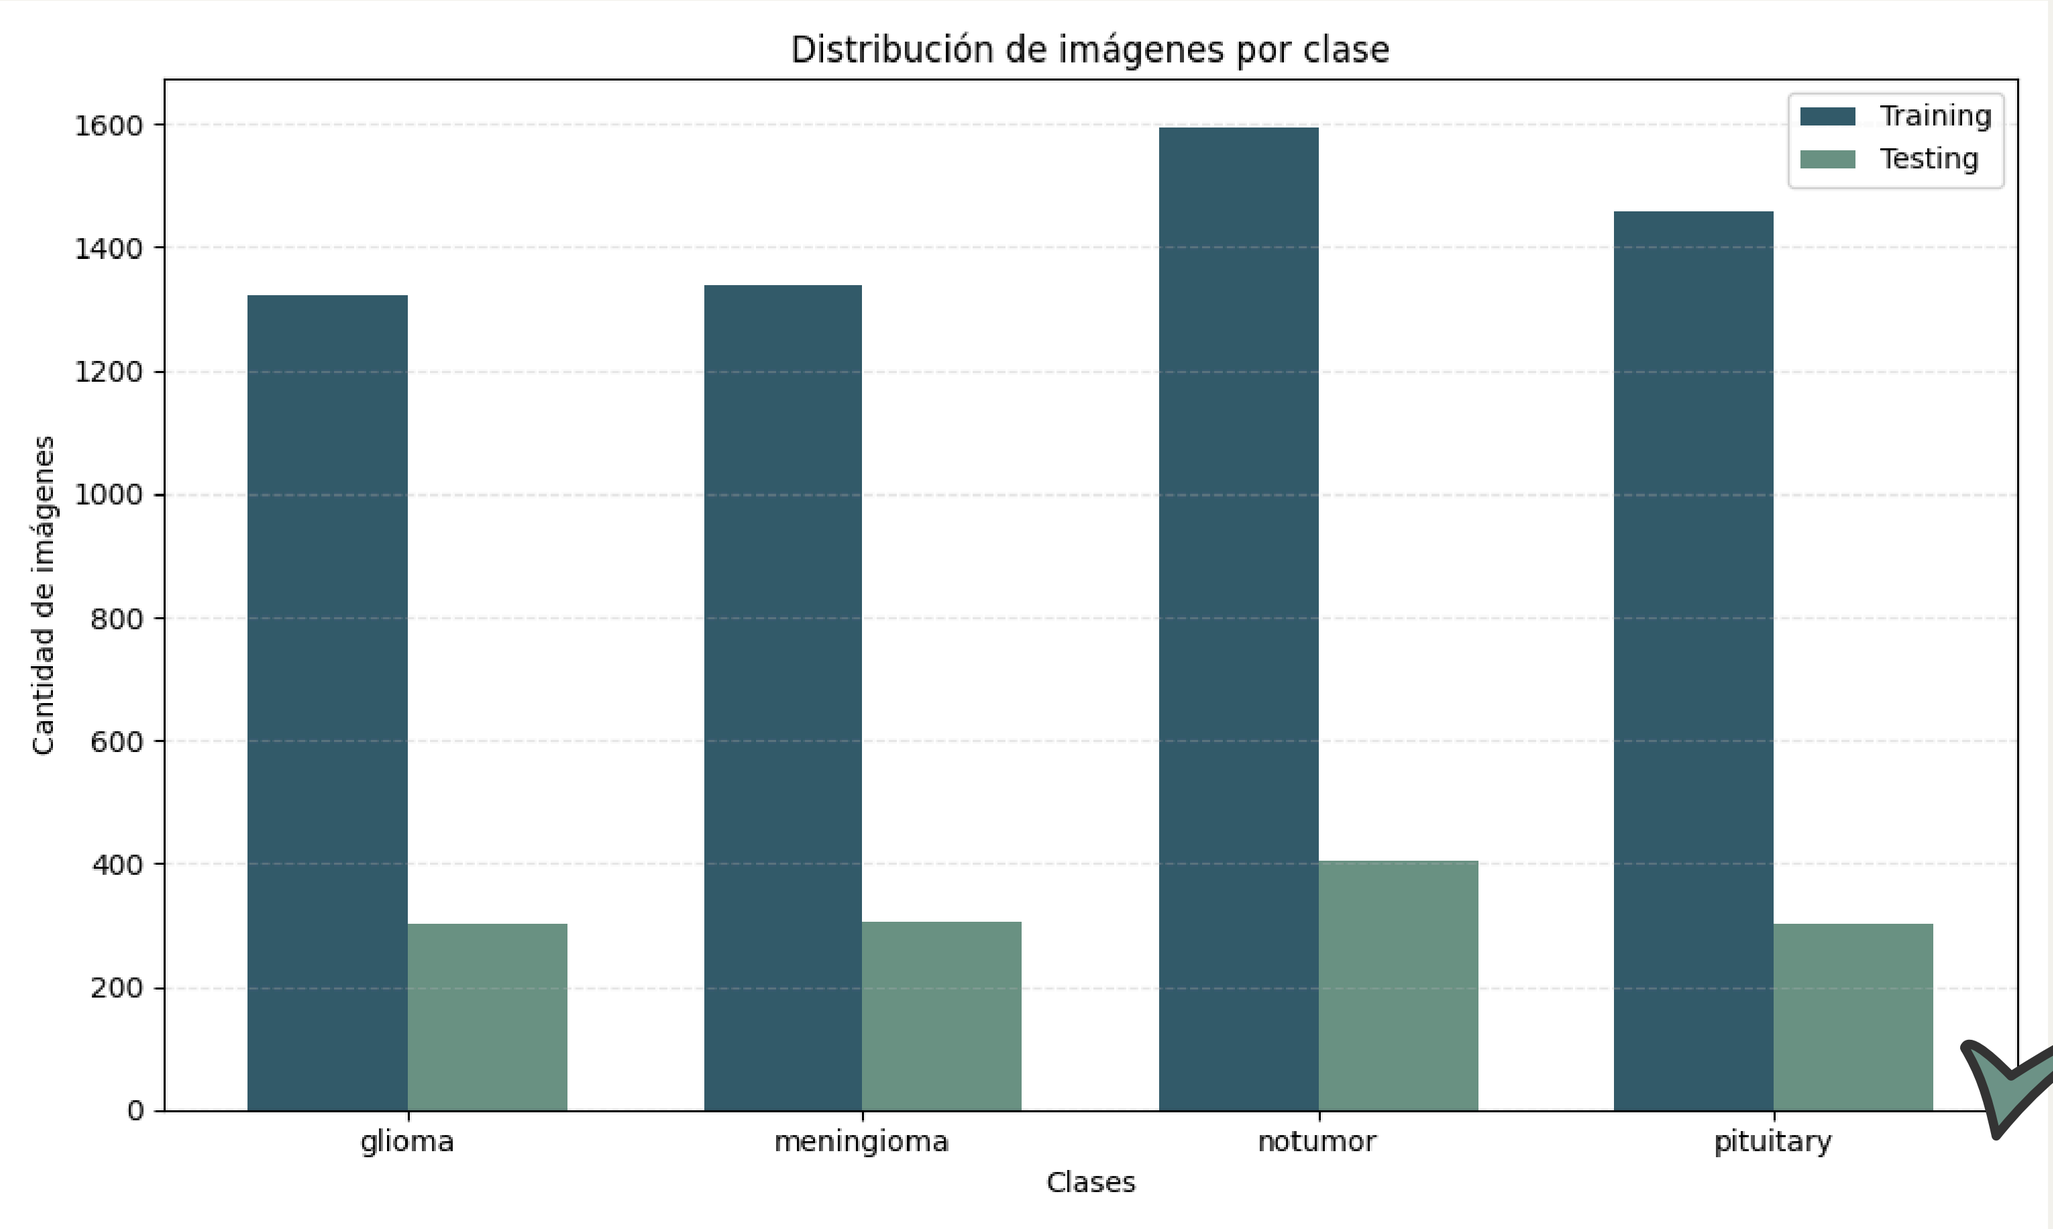

Ejemplos de imagenes con diferentes tamaños

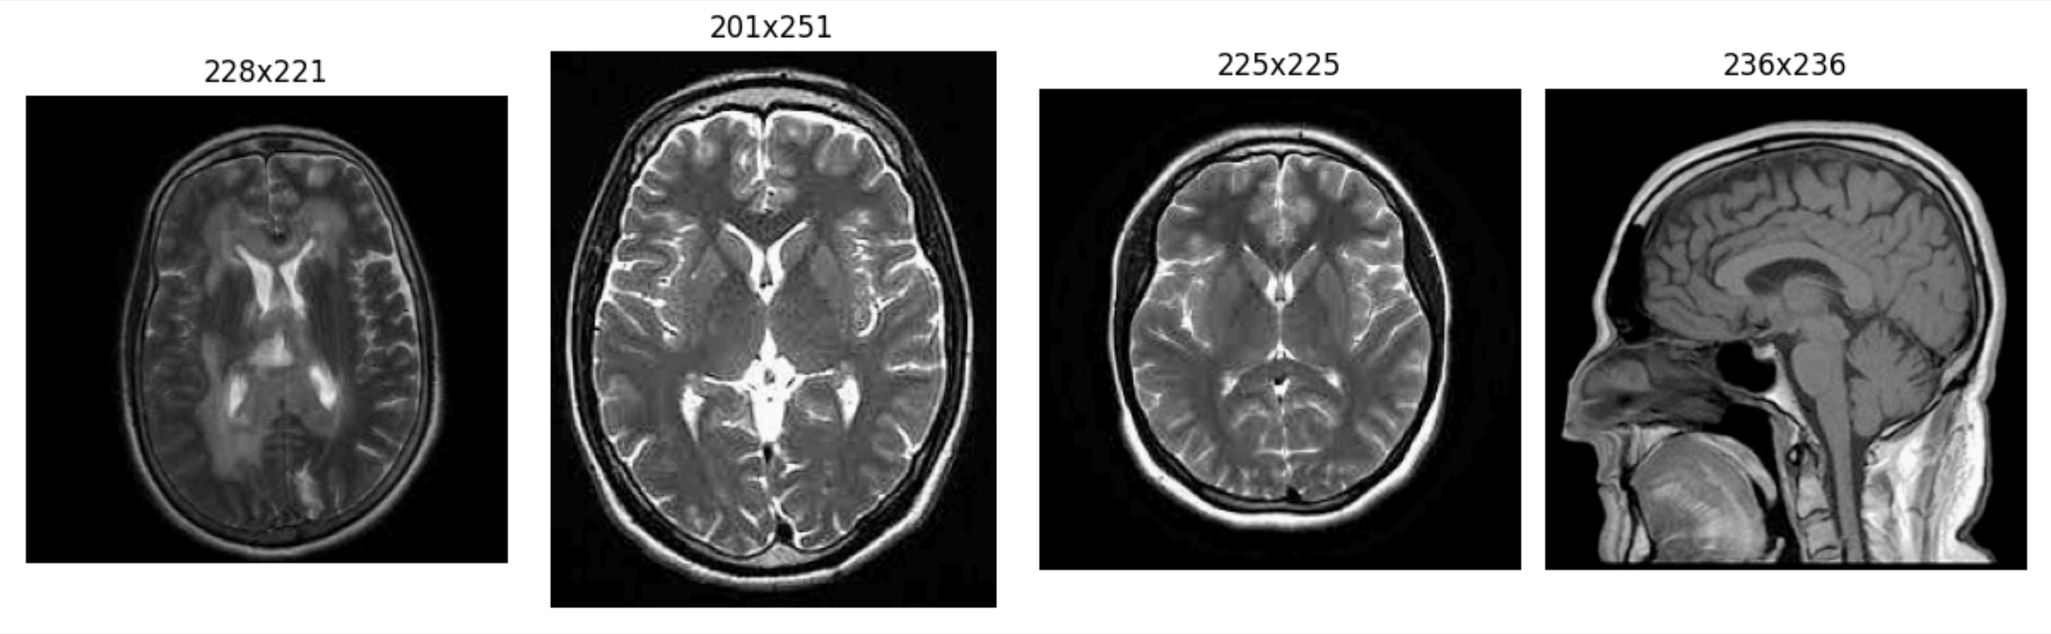

PREPROCESADO

Las imágenes se redimensionaron a 224x224 píxeles para ser compatibles con la red VGG16.

Tambien se aplico una función **preprocess_input()** del módulo keras.applications.vgg16, que:

- Convierte el formato de las imágenes de RGB a BGR.
- Resta la media de cada canal de color.
- Permite que las imagenes se normalicen igual que durante el entrenamiento del modelo original.

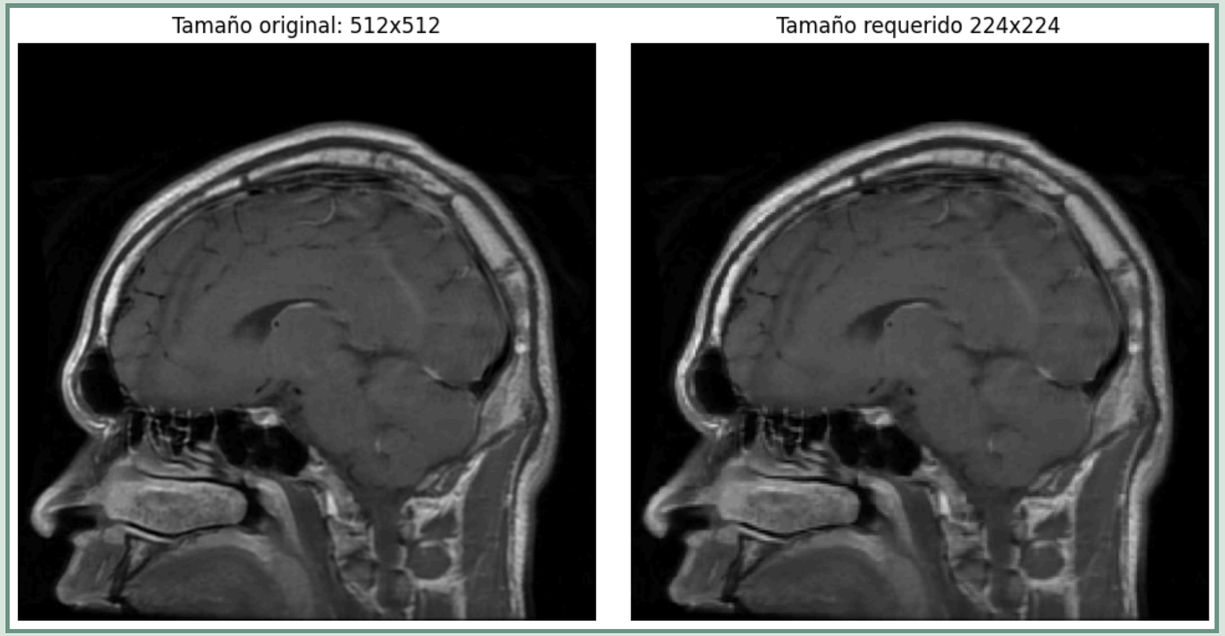

PREPROCESADO

Se aplicó **Data Augmentation** para aumentar la variedad del set de entrenamiento y mejorar la generalización:

- Rotación aleatoria
- Zoom
- Flip horizontal
- Desplazamiento horizontal y vertical

Se usó **ImageDataGenerator** para aplicar estas transformaciones automáticamente durante el entrenamiento y tambien para preparar los batches

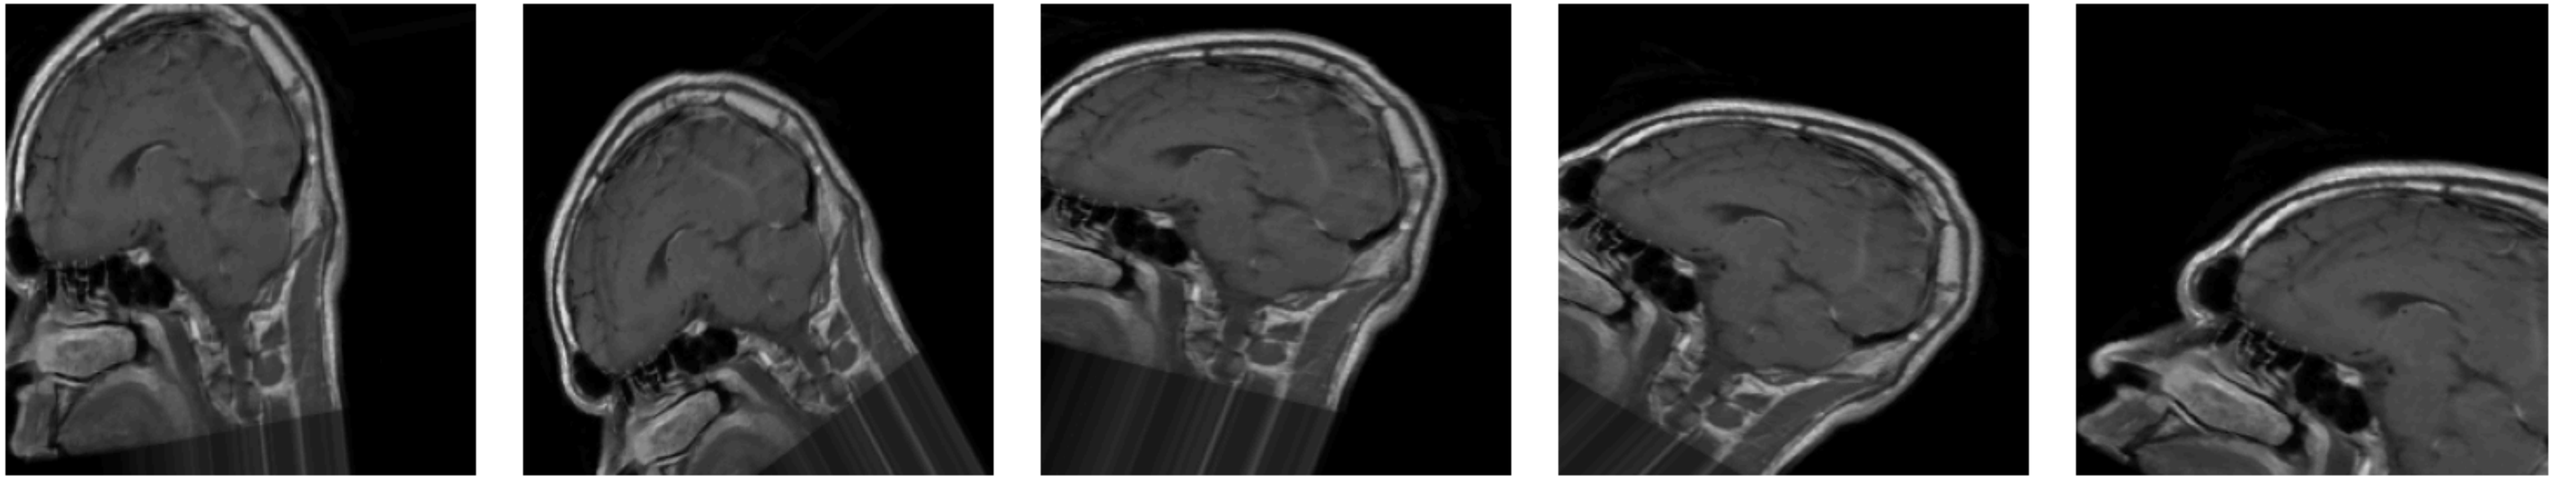

MODELO VGG16 PREENTRENADO

¿Que es VGG16?

VGG16 es una red neuronal convolucional profunda desarrollada por el Visual Geometry Group (VGG) que esta entrenada con ImageNet, una base de datos que contiene muchas imágenes clasificadas en distintas categorías, lo que le permite reconocer patrones visuales generales como bordes, formas y texturas.

¿Que es el Transfer Learning?

En lugar de entrenar un modelo desde cero, se aplicó la técnica de transfer learning, que consiste en reutilizar el conocimiento aprendido por VGG16 en ImageNet y adaptarlo a una nueva tarea. En este proyecto, se conservaron las capas convolucionales del modelo y se reemplazaron las capas finales por una nueva estructura específica para clasificar nuestras 4 clases.

VGG16

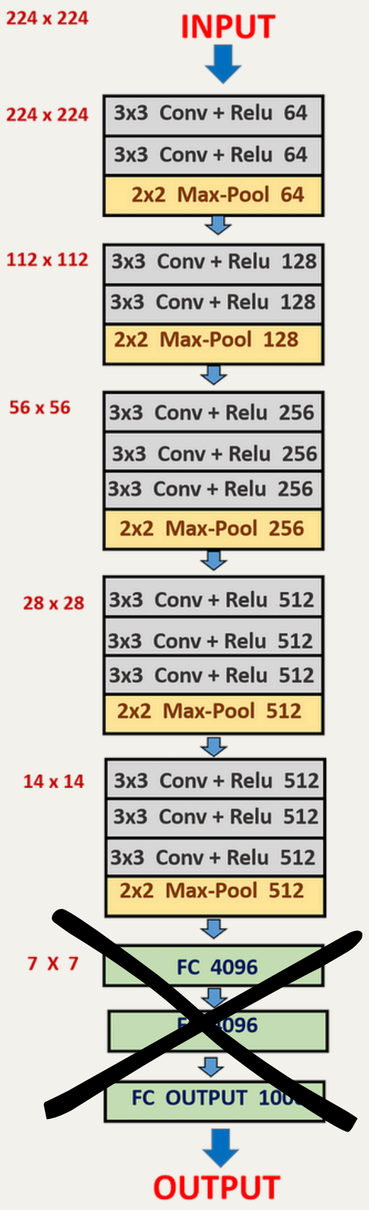

- Se desactivo la parte final del modelo (Fully Connected Top) para poder personalizar la salida
- Se agregaron capas densas al final para clasificar en 4 clases.
- Se congelaron los pesos de las capas convolucionales para mantener las características aprendidas en ImageNet y evitar que se modifiquen durante el entrenamiento.

```python
model = models.Sequential([
    base_model,
    layers.Flatten(),
    layers.Dense(256, activation='relu'),
    layers.Dropout(0.5),
    layers.Dense(64, activation='relu'),
    layers.Dropout(0.3),
    layers.Dense(4, activation='softmax')
])
```

ENTRENAMIENTO

- Se utilizó el optimizador Adam, conocido por su eficiencia y rápida convergencia.
- La función de pérdida empleada fue categorical_crossentropy, adecuada para clasificación multiclase.
- Se implementó EarlyStopping para detener el entrenamiento en caso de que la pérdida de validación no mejorara, ayudando a prevenir el sobreajuste.
- El modelo se entrenó durante 20 épocas con un batch size de 32.

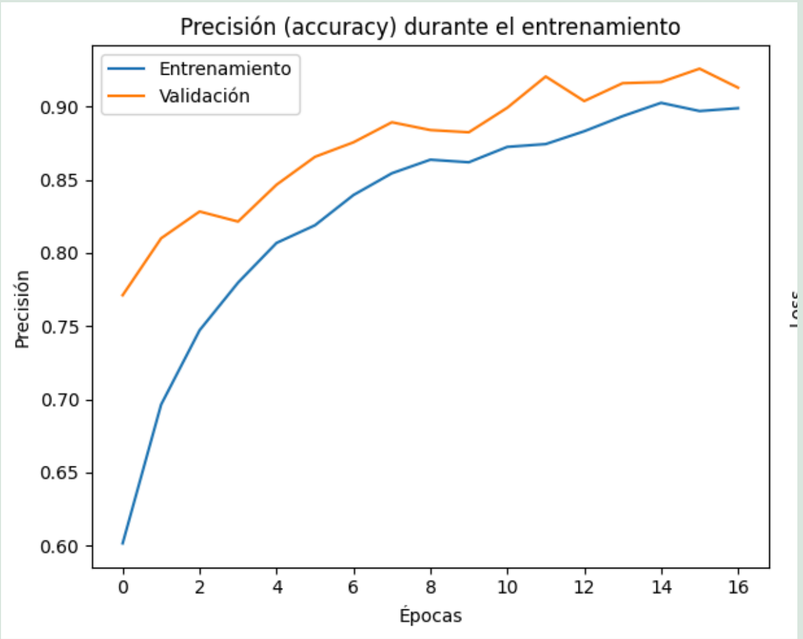

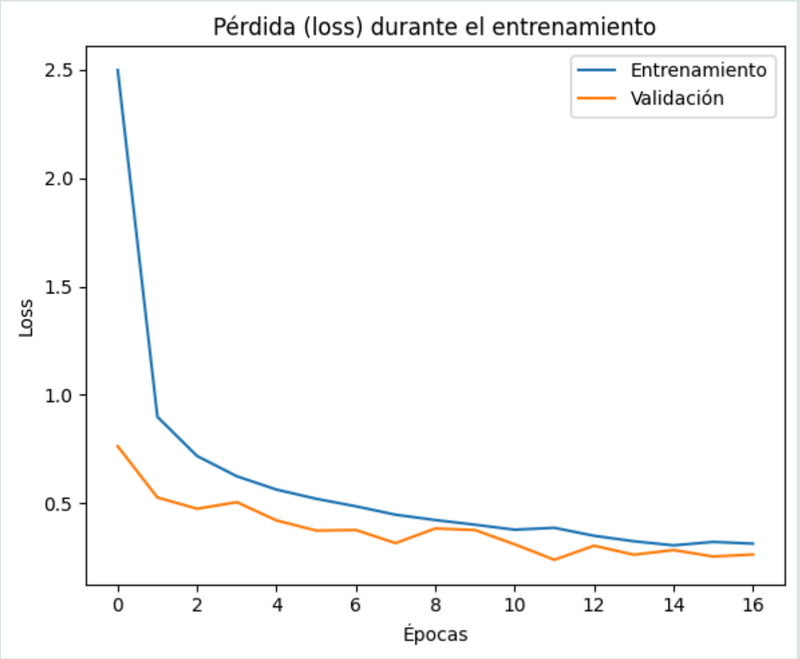

RESULTADOS

Clase	Precision	Recall	F1-Score	Soporte
Glioma	93	87	90	300
Meningioma	86	82	84	306
No Tumor	95	99	97	405
Pituitary	94	98	96	300
Métrica Global	**Valor**			
Accuracy	92			
Macro Promedio	92			
Weighted Promedio	92			
Total Muestras	1311			

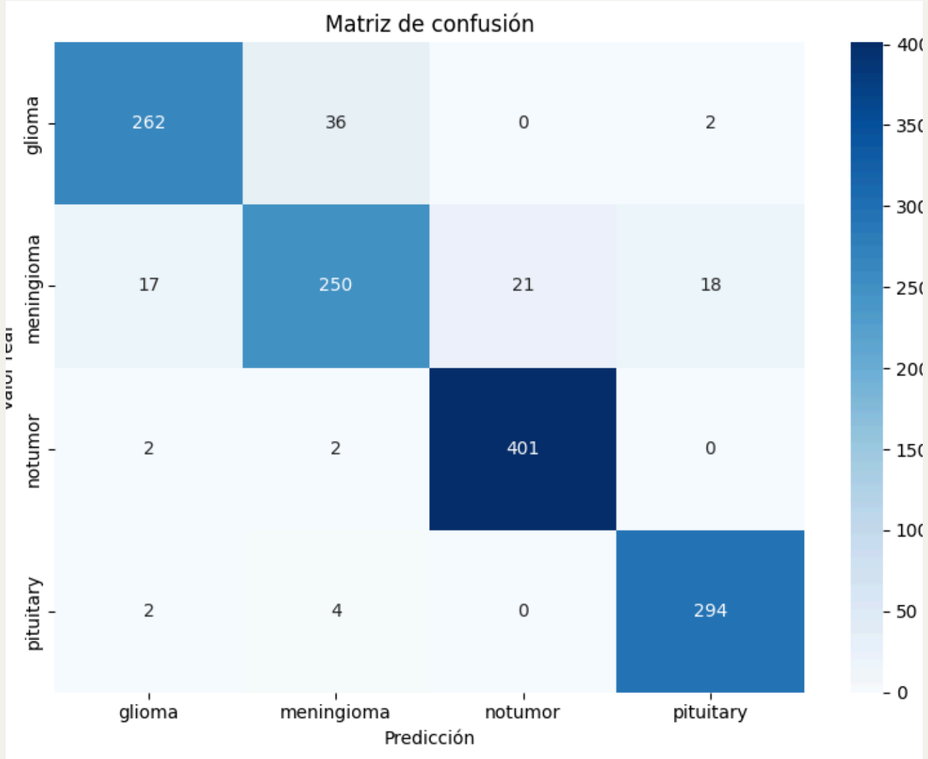

15 muestras aleatorias del test

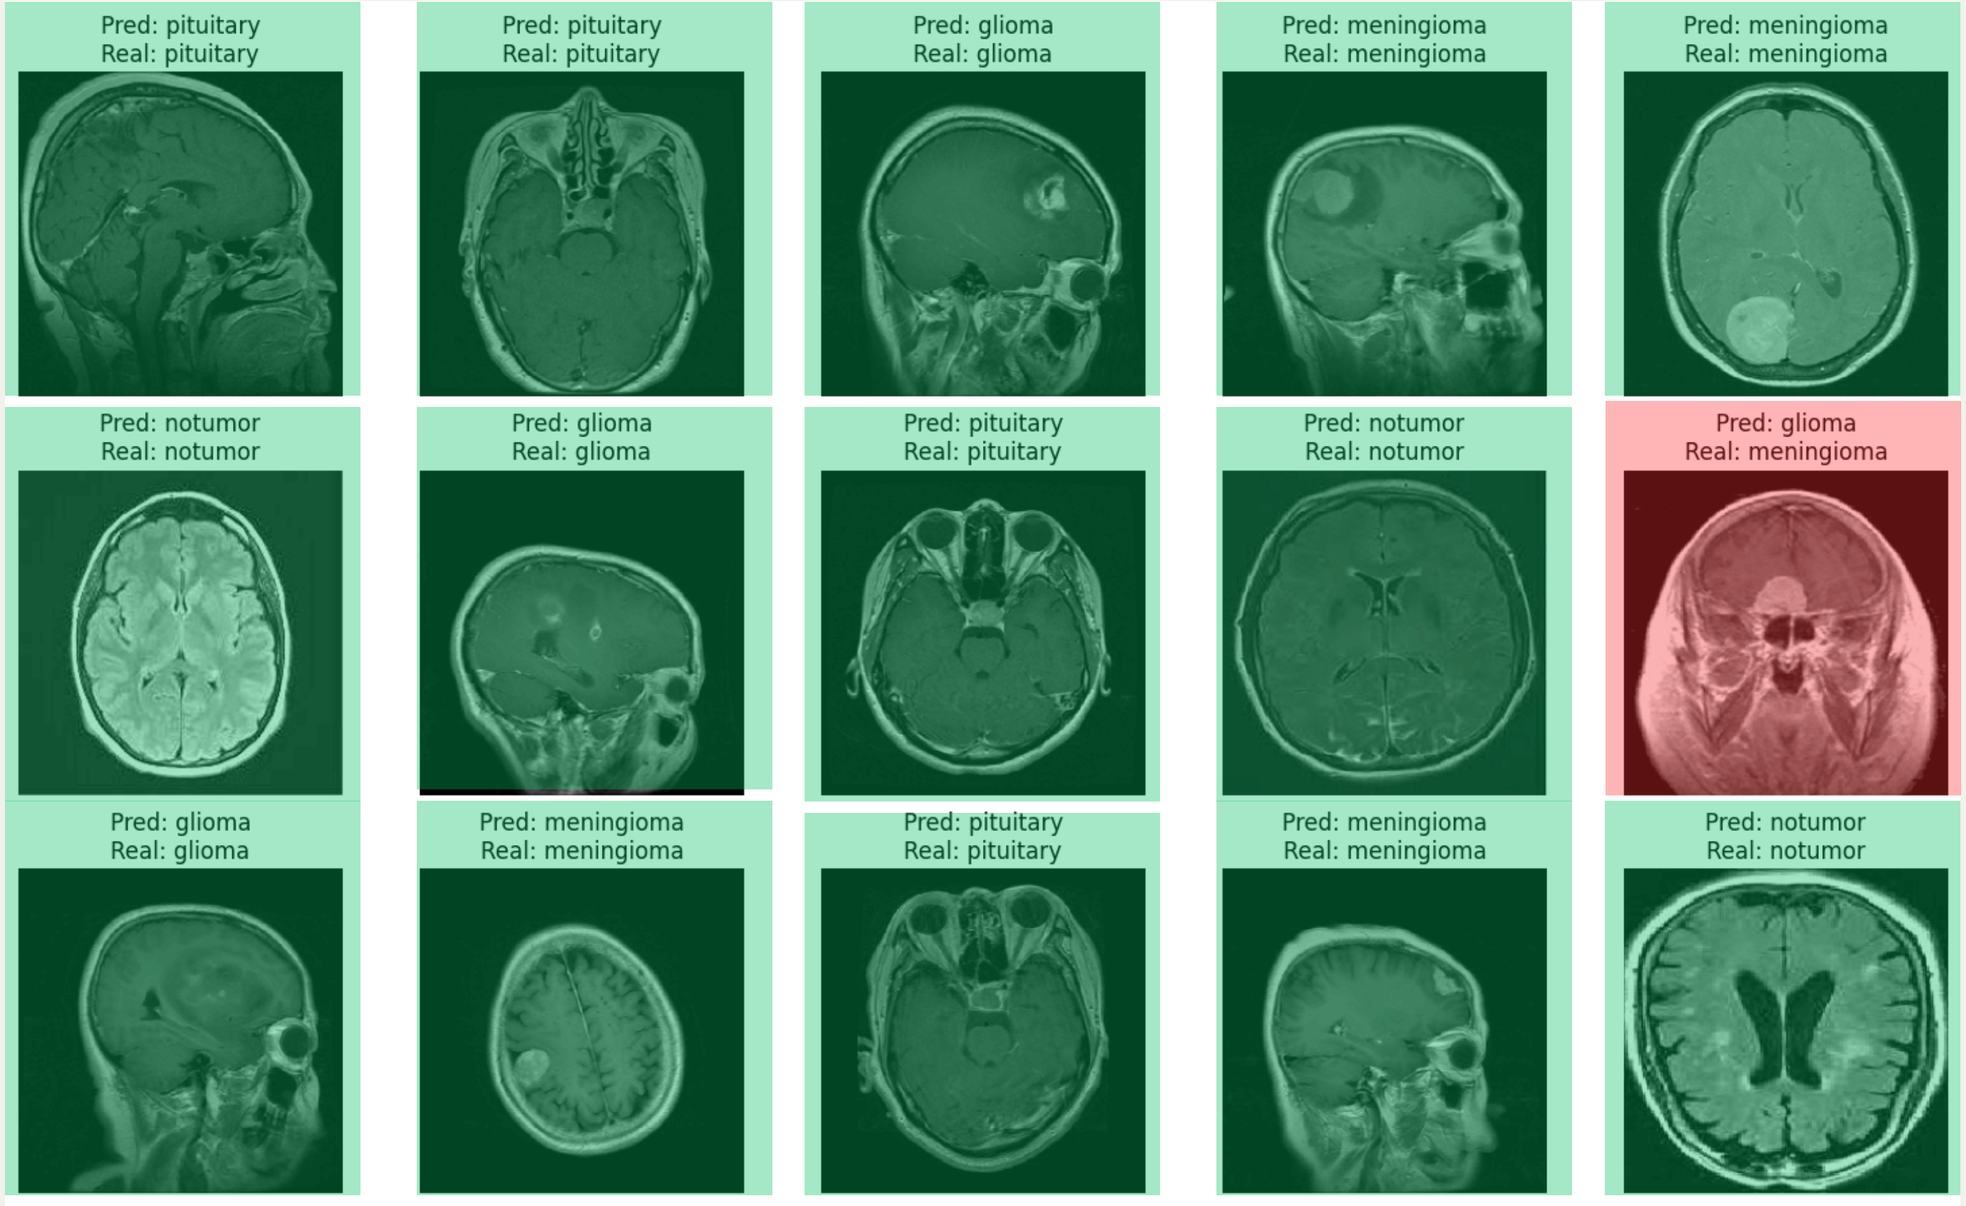

Ejemplos de errores del modelo

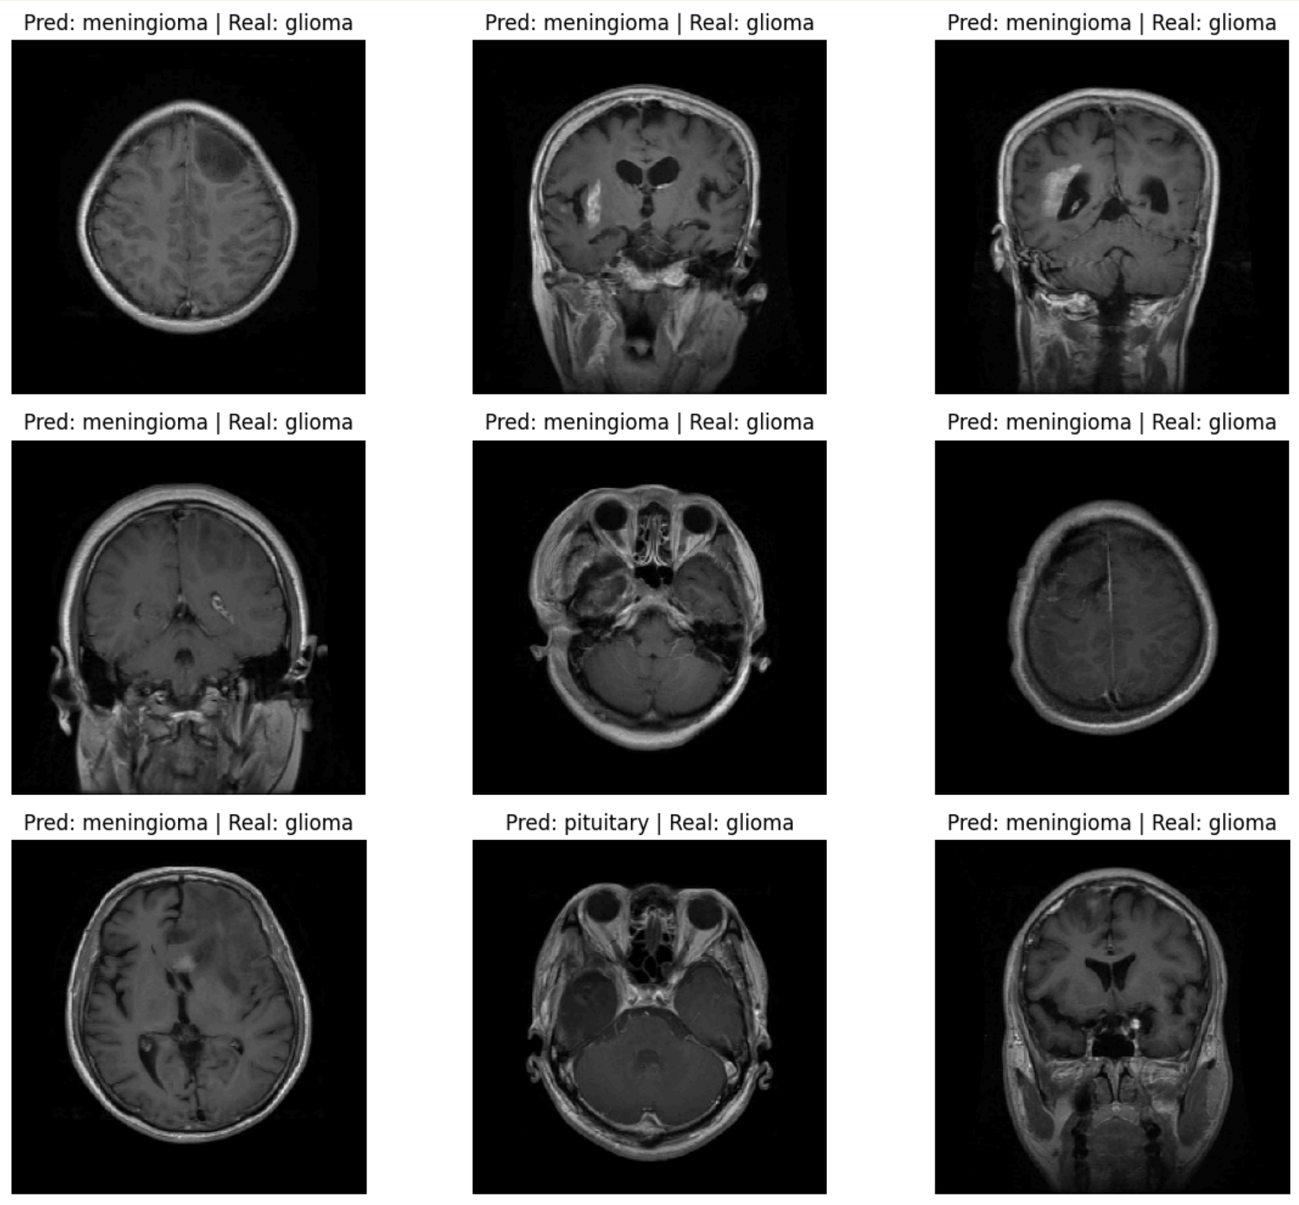

CONCLUSIONES

1. Se utilizó el modelo VGG16 preentrenado con transferencia de aprendizaje para clasificar tumores cerebrales en imágenes de RMN.
2. Al personalizar la salida y congelar las capas convolucionales, se logró una precisión del 92%, con buen desempeño en todas las clases.
3. El uso de data augmentation mejoró la generalización; sin él, el modelo presentaba menor rendimiento. EarlyStopping fue útil para evitar overfitting al detener el entrenamiento cuando la validación dejaba de mejorar.
4. Los resultados muestran que las CNN son efectivas para tareas de diagnóstico asistido por imágenes médicas.

MUCHAS GRACIAS